

蔬菜类商品的自动定价与补货决策

摘要

蔬菜类商品保鲜期短、品相随时间变差，商超需每日做出补货与定价决策。本文基于某商超 2020 年 7 月至 2023 年 6 月六个蔬菜品类 251 个单品的销售流水、批发价格和损耗率数据，建立了从品类关联分析、品类级补货定价到单品级选品优化的递进式数学模型。

对于问题一，首先对销售流水按品类和日期聚合，经正态性检验发现全部品类拒绝正态分布假设，采用 Spearman 秩相关系数分析品类间关联关系，接着使用 K-means++ 聚类算法对 159 个销售稳定的单品按销量规模和波动性聚类，最后对各品类日销售量进行分布拟合。结果表明，Spearman ρ 范围为 $[-0.194, 0.625]$ ，花叶类与花菜类关联最强 ($\rho = 0.625$)，单品被聚为低量高波动与高量中波动两类 (Silhouette=0.463)，对数正态分布最能刻画蔬菜日销售量的分布形态。

对于问题二，首先建立 Prophet 时间序列分解模型分离趋势、周/年季节性和中国节假日效应，接着从数据自行估计各品类需求价格弹性，然后建立约束报童模型以加成率和订货量为联合决策变量，通过二维网格搜索求解最优补货与定价策略。结果表明，单日总期望利润为 2,918 元 (折扣回收率 $k = 0.66$, $k \in [0.50, 0.75]$ 对应区间 $[2, 362, 3, 713]$ 元), 较 ARIMA+ 固定加成 baseline (723 元/天) 提升 304%。优化加成率在 103.6%–128.2% 之间，品类间有充分区分。

对于问题三，首先从 6 月 24–30 日可售品种中过滤日均销量 ≥ 2.5 kg 的单品得到 31 个 (恰好落在 27–33 范围内)，接着各单品独立运行报童优化确定订货量与定价。结果表明，单日总期望利润为 1,327 元，较固定加成 baseline (465 元) 提升 185%。全部六个品类需求满足率均超过 78%，水生根茎类最低 (78.6%)，其余品类超过 150%。

对于问题四，基于前三问建模过程中实际暴露的数据局限性，建议商超优先采集每日库存与缺货记录、折扣原因分类码和天气数据，以提高最敏感参数 k 的估计精度和需求预测质量。模型具有清晰的数学结构和可解释的参数，关键数值结论均经过参数扰动和敏感性检验。

关键词： 蔬菜定价；补货决策；Spearman 秩相关；Prophet 时间序列分解；报童模型；K-means++ 聚类

目录

一、引言	1
1.1 问题背景	1
1.2 问题重述	1
二、总体分析	1
三、模型假设	2
四、符号说明	2
五、模型的建立与求解	3
5.1 问题一的模型的建立和求解	3
5.1.1 具体分析	3
5.1.2 模型准备	3
5.1.3 模型建立	4
5.1.4 模型求解	4
5.2 问题二的模型的建立和求解	6
5.2.1 具体分析	6
5.2.2 模型准备	6
5.2.3 模型建立	7
5.2.4 模型求解	8
5.3 问题三的模型的建立和求解	10
5.3.1 具体分析	10
5.3.2 模型准备	11
5.3.3 模型建立	11
5.3.4 模型求解	12
5.4 问题四的模型的建立和求解	13
5.4.1 具体分析	13
5.4.2 模型准备	14
5.4.3 模型建立	14
5.4.4 模型求解	15
六、模型检验与分析	15
6.1 误差分析	15
6.2 灵敏度分析	16

七、模型的评价	17
7.1 模型的优点	17
7.2 模型的缺点	17
八、模型的改进与推广	18
8.1 模型的改进	18
8.2 模型的推广	18
参考文献	19

一、引言

1.1 问题背景

生鲜商超中蔬菜类商品保鲜期短，品相随销售时间增加而变差，大部分品种当日未售出则隔日无法再售。商超需根据历史销售和需求情况每日补货，但进货交易时间在凌晨 3:00–4:00，商家须在不确切知道具体单品和进货价格的情况下做出补货决策。蔬菜的定价一般采用成本加成定价方法，商超对运损和品相变差的商品通常进行打折销售。可靠的市场需求分析对补货决策和定价决策尤为重要。从需求侧看，蔬菜类商品销售量与时间存在关联关系；从供给侧看，蔬菜供应品种在 4 月至 10 月较为丰富，商超销售空间的限制使得合理的销售组合极为重要。

题目提供某商超六个蔬菜品类（花叶类、辣椒类、食用菌、水生根茎类、茄类、花菜类）共 251 个单品的数据：附件 1 为商品信息，附件 2 为 2020 年 7 月 1 日至 2023 年 6 月 30 日的销售流水明细（878,503 条交易记录），附件 3 为同期批发价格数据，附件 4 为近期损耗率数据。本文仅使用附件 4 中的可见工作表（单品级损耗率），品类级损耗率通过附件 1 与附件 4 的关联自行计算。

1.2 问题重述

问题 1：分析蔬菜各品类及单品销售量的分布规律及相互关系。

问题 2：以品类为单位，分析销售总量与成本加成定价的关系，给出各品类 2023 年 7 月 1–7 日的日补货总量和定价策略，使商超收益最大。

问题 3：在销售空间有限的情况下制定单品补货计划，可售单品总数 27–33 个，各单品订购量 ≥ 2.5 kg。根据 6 月 24–30 日可售品种，给出 7 月 1 日的单品补货量和定价策略，在尽量满足市场对各品类需求的前提下使收益最大。

问题 4：建议商超还需采集哪些数据，说明这些数据对解决上述问题的帮助和理由。

二、总体分析

本文的四个问题构成从描述性分析到优化决策再到建议的递进逻辑链条。问题一通过对历史销售数据进行统计分析和聚类，揭示蔬菜品类及单品的销售分布规律和关联关系，为后续建模提供特征选择依据。问题二在问题一的基础上，以品类为单位建立需求预测与报童优化模型，确定品类级的最优补货量和定价策略。问题三进一步细化到单品层面，在销售空间约束下筛选单品并逐一优化，使品类需求得到充分满足。问题四基于前三问建模过程中实际暴露的数据局限性，提出有针对性的数据采集建议。四个问题环环相扣，形成从数据探索到模型构建再到决策建议的完整分析框架。

三、模型假设

为简化问题，本文做出以下假设：

- **假设 1：**蔬菜当日未售出则隔日无法再售，每日为一独立库存周期。该假设为题目原话，是报童模型单周期框架的基础。
- **假设 2：**定价采用成本加成定价方法 $P = (1 + \alpha)C$ 。该假设依据题目明确要求，加成率 α 为决策变量。
- **假设 3：**打折为被动清仓行为，折扣回收率 $k = 0.66$ 。该假设经人工确认， k 从打折交易数据中估算（折扣价与正价比值的中位数），论文同时报告 $k \in [0.50, 0.75]$ 的对应区间。
- **假设 4：**历史销售数据可代表未来需求趋势。该假设为所有时间序列预测模型的基础，通过留出集验证和跨年稳定性分析进行检验。
- **假设 5：**损耗率在预测期内恒定。题目仅提供近期盘点损耗率，模型将其视为常数。
- **假设 6：**退货可忽略。退货仅 461 条（占总记录的 0.05%），数据清洗时已剔除。
- **假设 7：**Q2 以品类为单位不考虑销售空间约束。题目仅在问题三提出销售空间限制，该假设经人工确认。

四、符号说明

本文使用的主要符号及其含义如表1所示。

表 1 符号说明

符号	说明
i	品类索引, $i = 1, \dots, 6$
j	单品索引
t	日期索引 (天)
$S_{i,t}$	品类 i 在第 t 天的总销售量 (kg)
ρ_{ab}	品类 a 与 b 的 Spearman 秩相关系数
$\hat{D}_{i,t}$	Prophet 对品类 i 在第 t 天的需求预测 (kg)
$\alpha_{i,t}$	品类 i 在第 t 天的加成率 (决策变量)
$P_{i,t}$	品类 i 在第 t 天的销售定价 (元/kg)
$Q_{i,t}$	品类 i 在第 t 天的订货量 (kg, 决策变量)
$C_{i,t}$	品类 i 在第 t 天的批发价 (元/kg)
$C_{i,t}^{\text{eff}}$	有效单位成本 $C_{i,t}/(1 - L_i)$ (元/kg)

表 1 符号说明 (续)

符号	说明
L_i	品类 i 的平均损耗率
k	折扣回收率 (打折价/正价)
e_i	品类 i 的需求价格弹性
$\pi_{i,t}$	品类 i 在第 t 天的期望利润 (元)
Π	总利润 (元)
γ_i	品类 i 的需求满足率
$d_{\min}$	最小陈列量 (2.5 kg)
N	入选单品数
μ_j, σ_j	单品 j 的日均销量 (kg) 及其标准差
ℓ_j	单品 j 的损耗率 (%)

五、模型的建立与求解

5.1 问题一的模型的建立和求解

5.1.1 具体分析

问题一要求分析蔬菜各品类及单品销售量的分布规律及相互关系,属于描述性分析和统计推断类问题。本问采用 Spearman 秩相关系数进行品类间关联分析,以 K-means++ 聚类分析单品销售模式,并通过经验分布拟合刻画销售量的分布形态。

首先对销售流水按品类和日期聚合为日销售量矩阵 (1049 天 $\times$ 6 品类),剔除退货 (461 条, 0.05%) 和 5 个从未销售的单品。然后计算 Spearman 秩相关系数量化品类间关联,以轮廓系数确定最优聚类数对单品分组,最后对各品类日销售量拟合候选分布 (正态、对数正态、Gamma) 并以 KS 检验选择最优分布。

5.1.2 模型准备

在进行建模之前,需要对原始销售流水数据进行聚合和清洗。原始数据来源于附件 2, 包含 878,503 条交易记录,涵盖 2020 年 7 月 1 日至 2023 年 6 月 30 日。

经检查发现以下问题: 退货 461 条 (0.05%), 5 个单品在全部三年中无任何销售记录, 87 个单品销售天数不足 30 天。针对上述问题, 按以下步骤进行预处理: 第一步, 剔除退货记录和从未销售的单品; 第二步, 将交易数据按品类和日期聚合为日销售量; 第三步, 单品聚类分析仅纳入销售天数 ≥ 30 的单品 (159/246), 以确保特征估计的可靠性。预处理后, 得到 1049 天 $\times$ 6 品类的日销售量矩阵。

该问题本质上是一个探索性数据分析问题，需要在数据非正态的前提下选择合适的统计方法。全部分个品类均拒绝 D'Agostino-Pearson 正态性检验 ($p < 10^{-75}$)，因此 Pearson 相关系数假设不成立。Spearman 秩相关系数作为非参数方法，对分布无要求且对异常值稳健，是更合适的选择。K-means++ 聚类通过优化初始质心选择可得到比标准 K-means 更稳定的分组结果。因此本文选择 Spearman 秩相关作为主要关联分析方法，K-means++ 作为聚类算法。

综上所述，本节完成了数据预处理和方法选型，接下来将建立数学模型并进行求解。

5.1.3 模型建立

针对问题一，本节从关联分析和聚类分析两个角度建立模型。

步骤 1: Spearman 秩相关模型

对品类 a 和 b 的日销售量序列 $S_{a,t}$ 和 $S_{b,t}$ ，将其转换为秩次 $R(S_{a,t})$ 和 $R(S_{b,t})$ ，计算 Spearman 秩相关系数：

$$\rho_{ab} = \frac{\text{Cov}(R(S_a), R(S_b))}{\sigma(R(S_a)) \cdot \sigma(R(S_b))} = 1 - \frac{6 \sum_t d_t^2}{n(n^2 - 1)} \quad (1)$$

其中 $d_t = R(S_{a,t}) - R(S_{b,t})$ ， $n = 1049$ 为观测天数。 $\rho_{ab} > 0$ 表示两品类销售量呈同向变动趋势， $\rho_{ab} < 0$ 表示反向变动。

步骤 2: K-means++ 聚类模型

对 159 个销售天数 ≥ 30 的单品，构建特征向量 $\mathbf{x}_j = (\bar{s}_j, \sigma(s_j), \text{CV}(s_j), \bar{p}_j)$ ，经对数变换后进行 K-means++ 聚类。目标函数为簇内平方和最小化：

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{\mathbf{x} \in C_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \quad (2)$$

其中 $\boldsymbol{\mu}_k$ 为簇 k 的质心。最优 K 通过轮廓系数最大化选择：

$$\text{Sil}(K) = \frac{1}{N} \sum_{j=1}^N \frac{b(j) - a(j)}{\max\{a(j), b(j)\}} \quad (3)$$

其中 $a(j)$ 为样本 j 到同簇其他样本的平均距离， $b(j)$ 为到最近异簇的平均距离。

步骤 3: 分布拟合

对每个品类的日销售量序列，分别拟合正态、对数正态和 Gamma 分布，通过 Kolmogorov-Smirnov 检验的 p 值选择最优分布。

5.1.4 模型求解

基于上述模型，本节利用 Python (scipy.stats, scikit-learn) 进行求解。核心参数：随机种子 42，K-means++ 重启动次数 10。

求解得到以下结果。Spearman 秩相关系数矩阵如图1所示， ρ 范围为 $[-0.194, 0.625]$ ，均值 $|\rho| = 0.395$ 。花叶类与花菜类的正相关最强 ($\rho = 0.625$)，花叶类与食用菌次之 ($\rho = 0.590$)。茄类与水生根茎类呈唯一负相关 ($\rho = -0.194$)，茄类与其他品类的关联普遍较弱 ($|\rho| < 0.33$)。




图 1 各品类日销售量 Spearman 秩相关系数矩阵

Bootstrap 重抽样（100 次）表明相关估计稳定，平均 ρ 标准差 0.026。跨年分析显示 2020–2021 年 ρ 向量高度一致 ($r = 0.824$)，2021–2022 年相关性减弱 ($r = 0.168$)，主要源于茄类品类的持续萎缩（日均销量从 26 kg 降至 19 kg，仅 10 个单品导致估计不稳定）和疫情后消费模式调整。

K-means++ 聚类在 $K = 2$ 时轮廓系数最大 (0.463)。簇 0 (72 个单品) 以辣椒类和食用菌为主，特征为低销量（均值 2.2 kg/天）、高波动 (CV=0.76)、高价格 (12.96 元/kg)；簇 1 (87 个单品) 以花叶类为主，特征为高销量（均值 12.4 kg/天）、中等波动 (CV=0.83)、低价格 (6.18 元/kg)。两簇内均包含全部六个品类，表明品类内部也存在销量分化。

分布拟合结果表明，对数正态分布是蔬菜日销售量最适用的分布族，花叶类 (KS $p = 0.544$)、花菜类 ($p = 0.879$) 和茄类 ($p = 0.991$) 均不拒绝对数正态假设。

月度销售量趋势如图2所示，花叶类在 11 月达到峰值，花菜类和食用菌在秋冬季节销售旺盛，呈现出明显的季节性模式。




图 2 各品类月销售量时间序列 (2020.07-2023.06)

综上所述，本节完成了品类间关联分析和单品聚类分析。Spearman 秩相关揭示了品类间差异化的关联结构（花叶类-花菜类-食用菌高度协同，茄类相对独立），K-means++ 聚类将单品按销量规模和波动性分为两类，对数正态分布较好地刻画了蔬菜日销售量的分布形态。这些结论为问题二和问题三的特征选择提供了量化依据。

5.2 问题二的模型的建立和求解

5.2.1 具体分析

问题二要求以品类为单位建立补货计划，分析销售总量与成本加成定价的关系，并给出未来一周的日补货总量和定价策略使商超收益最大，属于预测与优化混合问题。本问采用 Prophet 时间序列分解进行需求预测，以约束报童模型联合优化加成率和订货量。

首先对每个品类的日销售量序列进行 Prophet 分解，分离趋势、季节性和节假日效应，并从数据自行估计需求价格弹性。然后在需求预测和弹性估计的基础上，建立单周期报童模型，以加成率和订货量为联合决策变量，通过二维网格搜索求解最优策略。

5.2.2 模型准备

问题二以品类为单位，需将单品级数据按品类聚合。对每个品类 i ，计算每日总销售量 $S_{i,t}$ = 销量加权平均售价 $P_{i,t}$ 和加权平均批发价 $C_{i,t}$ 。剔除批发价 ≤ 0.01 元/kg 的 27 条异常记录（占批发价数据的 0.05%）。各品类平均损耗率从附件 4 可见 Sheet1 的单

品数据与附件 1 关联后按品类取均值计算：花菜类 14.14%，水生根茎类 11.97%，花叶类 10.28%，辣椒类 8.52%，食用菌 8.13%，茄类 7.12%。

需求价格弹性通过 Double-log 模型从数据估计：

$$\ln S_{i,t} = \beta_0 + e_i \ln P_{i,t} + \sum_k \gamma_k D_{k,t} + \varepsilon_{i,t} \quad (4)$$

其中 $D_{k,t}$ 包括星期和月份虚拟变量。估计结果如表2所示，全部弹性为负，符合需求定律。

表 2 各品类需求价格弹性估计

品类	价格弹性 e_i	R^2	显著性
水生根茎类	-1.01	0.144	$p < 0.001$
花叶类	-0.23	0.019	$p < 0.001$
花菜类	-0.73	0.098	$p < 0.001$
茄类	-0.40	0.032	$p < 0.001$
辣椒类	-0.38	0.072	$p < 0.001$
食用菌	-0.28	0.011	$p < 0.001$

R^2 介于 0.011–0.144，说明价格仅解释了需求变动的一小部分，大部分变动由季节性、节假日等因素驱动，支持将需求预测与价格弹性分阶段处理的策略。

该问题本质上是一个随机优化问题，需要在需求不确定下确定最优订货量和定价。常用方法包括报童模型、动态规划和鲁棒优化。报童模型是易腐品单周期库存的标准框架，数学结构清晰、可解释性强。本文选择 Prophet+ 约束报童模型作为主方法，ARIMA+ 固定加成为 baseline。

综上所述，本节完成了品类级数据聚合和价格弹性估计，为建模提供了输入数据和方法基础。

5.2.3 模型建立

针对问题二，本节从需求预测、成本定价和随机优化三个层面建立模型。

步骤 1：Prophet 时序分解

对每个品类的日销售量序列 $S_{i,t}$ ，采用 Prophet 模型分解：

$$S_{i,t} = g_i(t) + s_i(t) + h_i(t) + \varepsilon_{i,t} \quad (5)$$

其中 $g_i(t)$ 为趋势项（分段线性）， $s_i(t)$ 为周期项（傅里叶级数，周 + 年）， $h_i(t)$ 为中国节假日效应（含法定假日及调休窗口）， $\varepsilon_{i,t}$ 为残差。

步骤 2：成本加成定价

定价采用成本加成方法，加成率 $\alpha_{i,t} \geq 0$ 为决策变量：

$$P_{i,t} = (1 + \alpha_{i,t}) \cdot C_{i,t} \quad (6)$$

有效单位成本计入损耗：

$$C_{i,t}^{\text{eff}} = \frac{C_{i,t}}{1 - L_i} \quad (7)$$

步骤 3：报童模型

对每个品类 i 和日期 t ，单日期望利润为：

$$\pi_i(Q, \alpha) = P \cdot \mathbb{E}[\min(Q, D)] + kP \cdot \mathbb{E}[(Q - D)^+] - C_i^{\text{eff}} \cdot Q \quad (8)$$

其中 $P = (1 + \alpha)C_i$ 。第一项为正价销售收入，第二项为未售出商品按折扣价 kP 清仓的收入，第三项为含损耗的进货总成本。 $k = 0.66$ 为从打折数据估算的折扣价与正价比值的中位数。

需求 D 采用 Prophet 预测值 $\hat{D}_{i,t}$ 经价格弹性调整：

$$D_i(\alpha) = \hat{D}_{i,\text{Jul1}} \cdot \left(\frac{(1 + \alpha)C_i}{(1 + \bar{\alpha}_i)C_i} \right)^{e_i} \quad (9)$$

需求分布采用 Prophet 残差的经验分布（非参数分位数），以 Bootstrap 重抽样计算期望利润。

步骤 4：约束与求解

优化问题为 $\max_{\alpha \geq 0, 0 \leq Q \leq Q_{\max}} \pi_i(Q, \alpha)$ ，其中 $Q_{\max} = 1.5 \times \max_{\tau} S_{i,\tau}$ 为订货量上限。求解采用二维网格搜索（加成率 35 步 $\times$ 订货量因子 35 步），每点 5,000 次 Monte Carlo 抽样。

5.2.4 模型求解

基于上述模型，本节利用 Python (Prophet, scipy) 进行求解。Prophet 在 2023 年 5 月 31 日前数据训练，预测 31 天至 7 月 1 日，2023 年 6 月（30 天）作为留出集评估。

各品类 RMSE 为 7.7–34.1 kg，在全部六个品类上均优于 ARIMA baseline（如花叶类 34.1 vs 45.0 kg）。以花叶类为例，Prophet 分解结果如图3所示。




图3 花叶类 Prophet 时间序列分解（趋势 + 周周期 + 年周期 + 节假日）

各品类 2023 年 7 月 1 日的最优策略如表3所示。

表3 各品类最优补货与定价策略（2023 年 7 月 1 日）

品类	优化加成率	售价（元/kg）	订货量（kg）	期望利润（元）
水生根茎类	103.6%	24.51	54.7	287
花叶类	116.7%	6.46	254.3	854
花菜类	104.6%	22.82	79.3	316
茄类	113.2%	20.04	53.3	162
辣椒类	128.2%	18.21	183.5	699
食用菌	113.0%	10.12	174.6	599
合计	—	—	—	2,918

优化加成率（103.6%–128.2%）系统性高于历史均值（53.6%–78.2%），品类间有充分区分度（标准差 0.082）。图4展示了优化与历史的对比。




图4 各品类历史 vs 优化加成率对比

设置 ARIMA+ 固定加成 baseline：以 ARIMA 替代 Prophet，加成率固定为历史均值，订货量 $Q = \hat{D}^{\text{ARISM}} / (1 - L)$ 。相同利润函数和参数下，Baseline 单日总利润为 723 元。M1 增益 (+304%) 来自两方面：Prophet 更准确的季节性预测（如 ARIMA 将水生根茎类预测为 13.4 kg 而 Prophet 预测 30.6 kg），以及加成率优化。

对 7 月 2–7 日，每日基于 Prophet 向前一步预测，以当日最新批发价重新运行报童优化。七日总期望利润为 20,427 元 ($k = 0.66$)，对应区间 $[16,534, 25,991]$ 元 ($k \in [0.50, 0.75]$)。

综上所述，本节完成了品类级补货与定价的建模与求解。Prophet 有效分离了各时间分量，报童模型给出了差异化的最优加成率和订货量。模型增益可分解为预测精度提升和定价优化两个可解释的来源。

5.3 问题三的模型的建立和求解

5.3.1 具体分析

问题三在问题二品类级框架的基础上增加了三个约束：可售单品总数 $27 \leq N \leq 33$ ，各单品订购量 $Q_j \geq 2.5 \text{ kg}$ （最小陈列量），以及销售空间有限（以 SKU 数量约束间接体现）。目标为在尽量满足各品类市场需求的前提下，使 7 月 1 日的商超收益最大。本问属于带组合约束的优化问题。

本问将选品问题转化为过滤问题：首先从 6 月 24–30 日可售品种中过滤日均销量 $\geq 2.5 \text{ kg}$ 的单品，发现恰好得到 31 个（落在 27–33 范围内）。然后各单品在问题二的报童框架下独立优化加成率和订货量，需求满足通过惩罚项纳入目标函数。

5.3.2 模型准备

从 2023 年 6 月 24–30 日有销售记录的 49 个可售单品出发，计算各单品在该周的日均销量 $\bar{s}_j$ 。过滤条件为 $\bar{s}_j \geq 2.5 \text{ kg}$ 。过滤后得到 31 个单品，品类分布为花叶类 12 个、辣椒类 6 个、食用菌 5 个、水生根茎类 3 个、茄类 3 个、花菜类 2 个，全部六个品类均有代表。

为验证过滤阈值的稳健性，对 2.0–3.0 kg 范围内的阈值进行测试：

表 4 过滤阈值稳健性测试

阈值 (kg)	入选单品数	是否在 [27,33] 内
2.0	39	否（超出上限）
2.3	31	是
2.5	31	是
2.7	31	是
3.0	30	是

如表4所示，2.3–3.0 kg 均稳定产出 30–31 个单品，仅 2.0 kg 时超出上限。题目指定的 2.5 kg 恰好位于稳定区间。

各单品需求分布使用最近 30 天（2023 年 6 月）的日均销量 μ_j 和标准差 σ_j 估计。单品批发价以 6 月 30 日或最近日期为准，损耗率使用附件 4 可见 Sheet1 的单品级数据。需求满足的参考基准 D_i^{ref} 以 6 月 24–30 日的品类日均销量为准。

该问题本质上是一个组合优化问题——在 49 个候选单品中选择 27–33 个并确定各自的订货量和定价。常用方法包括背包模型 + 贪心算法、动态规划和多目标进化算法。由于过滤后发现 31 个单品自然落在范围内，选品退化为过滤问题，无需组合优化。本文选择过滤 + 单品报童优化的简单策略，VIKOR+NSGA-II 作为未激活的备用方案。

综上所述，本节完成了单品候选池构建和过滤阈值验证，为建模提供了入选单品集合。

5.3.3 模型建立

针对问题三，本节在问题二的报童框架下建立单品级优化模型。

步骤 1：单品需求估计

对每个入选单品 j ，以最近 30 天的日均销量 μ_j 和标准差 σ_j 作为需求分布参数。需求经品类价格弹性调整：

$$D_j(\alpha_j) = \mu_j \cdot \left(\frac{(1 + \alpha_j)C_j}{(1 + \bar{\alpha}_{\text{cat}})C_j'} \right)^{e_{\text{cat}}} \quad (10)$$

其中 e_{cat} 沿用问题二的自有弹性估计，确保跨题一致性。

步骤 2：单品报童优化

对每个单品 j 独立优化加成率和订货量：

$$\max_{\alpha_j \geq 0, Q_j \geq 2.5} P_j \cdot \mathbb{E}[\min(Q_j, D_j)] + kP_j \cdot \mathbb{E}[(Q_j - D_j)^+] - \frac{C_j}{1 - \ell_j/100} \cdot Q_j \quad (11)$$

其中 $P_j = (1 + \alpha_j)C_j$ ， $k = 0.66$ 同问题二。

步骤 3：需求满足惩罚项

根据”尽量满足市场需求”的要求，将需求满足作为惩罚项纳入目标函数：

$$\Pi_{\text{penalized}} = \sum_j \pi_j - \lambda \sum_i \max \left(0, \beta D_i^{\text{ref}} - \sum_{j \in \mathcal{I}_i} Q_j \right) \quad (12)$$

其中 λ 为惩罚权重， β 为需求满足阈值。

求解采用二维网格搜索（加成率 25 步 $\times$ 订货量因子 25 步），每点 3,000 次 Monte Carlo 抽样估计期望利润。

5.3.4 模型求解

基于上述模型，本节利用 Python（numpy, scipy）进行求解。Q2 的自有价格弹性估计作为跨题一致的弹性输入。

求解得到 31 个单品的最优策略，完整单品清单见支撑材料。各品类汇总结果如表5所示。单日总期望利润为 1,327 元，总订货量为 436.5 kg。

表 5 各品类单品汇总结果（2023 年 7 月 1 日）

品类	入选数	品类订货量 (kg)	需求基准 (kg)	满足率
水生根茎类	3	17.1	16.7	78.6%
花叶类	12	142.7	124.8	178.9%
花菜类	2	28.2	16.2	152.2%
茄类	3	39.2	19.0	190.0%
辣椒类	6	132.0	77.6	155.2%
食用菌	5	77.1	44.2	187.6%
合计	31	436.5	—	—

各品类需求满足率如图5所示，范围为 78.6%–190.0%，全部超过 50% 的 fallback 阈值。水生根茎类满足率最低（78.6%），原因是该品类仅 3 个单品达标且各自日均销量有限（约 5 kg/天）。其余五个品类满足率均超过 150%。




图 5 各品类需求满足率

设置固定加成 baseline：同 31 个单品采用历史平均加成率，订货量 $Q = \mu / (1 - \ell / 100)$ 。相同参数下 Baseline 单日利润为 465 元。M1 增益 (+185%) 完全来自单品级加成率优化——两方法使用完全相同的 31 个单品。单品加成率标准差 0.311，表明优化后的加成率在单品间有充分区分度。

在当前数据下，过滤法使全部品类满足率超过 78%，需求满足惩罚项实际未激活。31 个单品的完整策略表及代码见支撑材料。

综上所述，本节将单品级补货与定价分解为过滤与优化两步。31 个达标单品自然落在题目要求范围内，各单品独立优化实现了 1,327 元/天的利润，较固定加成 baseline 提升 185%。全部品类需求满足率超过 78%，模型给出了各品类差异化且可执行的单品级策略。

5.4 问题四的模型的建立和求解

5.4.1 具体分析

问题四要求基于建模经验，建议商超还需采集哪些数据并论证其帮助，属于定性分析与建议类问题。本问以前三问建模过程中实际暴露的数据局限性为基础，结合相关文献中的建议方向，提出按边际价值排序的数据采集建议。

在前三问的建模过程中，识别出以下关键数据局限性：无法区分零销量源于无需求还是缺货（影响需求估计的准确性），折扣回收率 k 的估算精度受折扣原因混杂影响（ k 是模型最敏感参数），Prophet 残差仍存在未被模型解释的结构性变动（暗示遗漏了天气、促销等外部变量），部分单品因缺乏上下架时间信息而难以判断其季节性模式，以及价格弹性估计受遗漏变量影响可能存在偏误。

5.4.2 模型准备

本问不涉及数学模型，而是以前三问的实际建模经验作为证据来源，与文献中的建议方向交叉验证。相关文献中，吴萌等（2024）在数据处理中揭示了缺货和库存数据的必要性，曹宇轩等（2024）建议采集天气、节假日和产地数据，陈妙霞等（2024）建议收集天气、竞争和消费者反馈数据。本文在此基础上，以 Q1–Q3 的实际数据缺口验证每条建议的边际价值，并按采集成本和预期收益排序。

5.4.3 模型建立

针对问题四，本节建立以边际价值为核心的数据建议排序框架。每条建议按两个维度评估：对模型关键薄弱环节的直接修正作用，以及采集可行性与成本。据此将建议分为高、中、低三个优先级，共九条。

步骤 1：高优先级建议（3 条）

(1) 每日实际库存与缺货记录。当前数据仅含销售流水，无法区分“零销量 = 无需求”和“零销量 = 缺货”。87 个单品销售天数不足 30 天、5 个单品从未销售——这些究竟是需求不足还是供应缺失，现有数据无法判断。采集每日库存数据可将需求估计从“销售量”修正为“销售量 + 缺货量”，直接改善 Prophet 预测和报童模型的需求输入。

(2) 折扣原因分类码。折扣回收率 k 是模型最敏感参数——问题二利润在 $k \in [0.50, 0.75]$ 区间内波动 44%。当前 $k = 0.66$ 为所有打折交易的全局中位数，但打折原因混杂：运损清仓（品相变差被迫打折）vs 库存过剩清仓（订货过多主动打折）。记录折扣原因码可分别估计运损折扣率和清仓折扣率，显著提高报童模型参数精度。

(3) 天气数据（温度、湿度、降水量）。Prophet 残差仍有显著的自相关结构（Ljung-Box $p \approx 0$ ），表明存在模型未捕捉的外部驱动因素。天气是蔬菜需求最可能的遗漏变量——高温加速蔬菜变质、暴雨减少客流、季节性温湿度影响特定品类需求。将天气数据作为 Prophet 的外生回归项引入，可降低残差自相关，提高预测精度。

步骤 2：中优先级建议（3 条）

(4) 单品上架与下架时间表，可区分季节性商品（特定季节才上架）和低销量常驻商品，使 Q3 候选单品池不被动依赖最近一周的销售快照。(5) 促销活动日历，Prophet 的内置中国节假日仅覆盖法定假日，不含商超自发的促销活动（如会员日折扣），作为额外虚拟变量可分离促销效应和自然需求。(6) 竞争对手价格数据，当前从自身数据的 log-log 回归估计价格弹性面临遗漏变量偏误——品类销售量的变化可能部分来自竞争对手的价格调整，竞争对手数据可改善交叉弹性估计。

步骤 3：低优先级建议（3 条）

(7) 消费者偏好与满意度调查，帮助识别上升或衰落中的单品，改善 Q3 单品选择的前瞻性。(8) 货架空间与陈列数据，可将 Q3 的定性空间约束转化为定量模型输入，替代当前以 SKU 数量间接表达的空间限制。(9) 产地与供应链数据，附件 1 中部分单

品名称已含供应来源编号（如数字编号表示不同供应来源），完整提供有助于批发价波动预测和供应风险评估。

5.4.4 模型求解

基于上述分析框架，将九条建议按优先级汇总如表6所示。

表 6 数据采集建议汇总

优先级	建议数据	对应建模薄弱环节
高	每日库存与缺货记录	需求-销量识别偏差（Q2, Q3）
高	折扣原因分类码	k 参数精度（Q2, Q3）
高	天气数据	Prophet 残差结构（Q2）
中	单品上下架时间表	候选单品池时效性（Q1, Q3）
中	促销活动日历	需求异常值识别（Q2）
中	竞争对手价格数据	弹性估计遗漏变量（Q2）
低	消费者偏好调查	单品选择前瞻性（Q3）
低	货架空间与陈列数据	空间约束定量化（Q3）
低	产地与供应链数据	批发价波动预测（Q2）

由表6可知，高优先级的三类数据（库存记录、折扣原因码、天气数据）对应模型中三个最关键的薄弱环节，且采集成本低（系统自动记录或从公开 API 获取）。中优先级的数据对模型精度有可量化改善但需要额外投入。低优先级数据有益但对模型结构的改变大于对参数的修正。

综上所述，本文基于 Q1–Q3 建模过程中实际暴露的数据局限性，按边际价值排序提出了九条数据采集建议。建议的优先级反映了每条数据对模型关键薄弱环节的直接修正作用和采集可行性，为商超的数据采集决策提供了量化依据。

六、模型检验与分析

为验证本文构建的模型的有效性和稳健性，进行以下检验。

6.1 误差分析

问题二中 Prophet 模型在 2023 年 6 月的 30 天留出集上评估预测精度，各品类 RMSE 与 MAPE 如表7所示。Prophet 在所有六个品类上的 RMSE 均优于 ARIMA baseline。

表 7 各品类预测误差分析

品类	Prophet RMSE (kg)	ARIMA RMSE (kg)	Prophet 优势
水生根茎类	10.7	7.6	ARIMA 略优
花叶类	34.1	45.0	Prophet 优 24%
花菜类	15.0	8.9	ARIMA 略优
茄类	7.7	10.3	Prophet 优 25%
辣椒类	19.9	28.3	Prophet 优 30%
食用菌	30.2	20.9	ARIMA 略优

如表7所示，Prophet 在大品类（花叶类、辣椒类）上优势显著，ARIMA 在小品类（水生根茎类、花菜类、食用菌）上 RMSE 更低。这是因为小品类季节性较弱，ARIMA 的短期自回归结构已足够捕捉；而大品类受季节性和节假日影响更强，Prophet 的多分量分解优势更为显著。

问题三中单品过滤阈值的稳健性已在模型准备中验证（见表4）。31 个入选单品的需求满足率范围 78.6%–190.0%，全部超过 50% 阈值，表明模型对过滤阈值具有一定容错空间。

6.2 灵敏度分析

对问题二和问题三的关键参数进行扰动分析，结果如表8所示。

表 8 关键参数灵敏度分析

参数	扰动范围	利润变动幅度	灵敏度评估
折扣回收率 k	[0.50, 0.75]	[−19%, +17%]	高敏感
价格弹性 e	$\times[0.7, 1.3]$	0%	不敏感
损耗率 L	$\times[0.8, 1.2]$	$\pm 2.4\%$	低敏感
订货上限 $Q_{\max}$	$\times[1.2, \infty)$	0%	不敏感

如表8所示，折扣回收率 k 是唯一的高敏感参数，论文已在问题二的结论中报告 $k \in [0.50, 0.75]$ 区间值 [2, 362, 3, 713] 元/天。价格弹性和订货量上限对利润无影响，原因是 $Q_{\max}$ 在所有测试中均未绑定——报童模型的最优订货量本身就在合理范围内。损耗率 $\pm 20\%$ 仅造成利润 $\pm 2.4\%$ 变动，模型对此参数稳健。

此外，Spearman 秩相关的 Bootstrap 重抽样（100 次，平均 ρ 标准差 0.026）验证了

Q1 相关估计的稳定性。跨年分析（2020–2022）揭示了疫情后消费模式的结构性变化（2022 年茄类与其他品类脱钩），论文已将此作为时效性局限加以说明。

七、模型的评价

7.1 模型的优点

- **数学结构清晰、可解释性强。** Prophet 将需求分解为趋势、季节性、节假日等可命名和可视化的分量，报童模型是易腐品库存管理的标准框架，加成率、订货量、折扣回收率等参数均可直接对应商超的经营决策变量。
- **方法选择有数据支撑。** Spearman 替代 Pearson 基于全部六个品类正态性检验失败的数据事实 ($p < 10^{-75}$)；Prophet 替代 ARIMA 基于留出集 RMSE 的系统性优势；自有弹性估计替代文献值的决策已有数据验证（与聂森等差异达 8 倍）。
- **基线可比、增益可分解。** Q2 和 Q3 的 Baseline 均使用与主方法完全相同的利润函数、参数和数据，增益可分解为预测精度提升和定价优化两部分，分析透明。
- **稳健性透明。** 关键参数敏感性全部量化： k 高敏感 ($\pm 20\%$)，弹性、损耗率、订货量上限均为低敏感， k 的敏感性已在论文中以区间值形式报告。
- **递进式建模。** Q1 的描述性分析为 Q2 提供特征选择依据，Q2 的品类级框架为 Q3 的单品级优化提供需求基准和弹性输入，四问逻辑连贯。

7.2 模型的缺点

- **需求识别偏误。** 无法区分零销量 = 无需求与零销量 = 缺货，所有需求估计实质上是对实际销售量而非真实需求量的建模。87 个稀疏单品的需求估计可靠性低。
- **预测外推风险。** Prophet 在 2023 年 6 月留出集上表现良好，但 7 月 1–7 日为纯预测，无验证数据。疫情后消费模式变化可能降低历史数据代表性。
- **简单弹性估计。** Double-log 回归 R^2 仅 0.011–0.144，遗漏变量（天气、竞争、促销）可能影响弹性精度。但稳健性分析表明弹性误差对最优解影响极小。
- **静态损耗率与单周期假设。** 损耗率假设恒定，未考虑季节性损耗差异。每日独立运行报童优化，未考虑日间需求序列相关。
- **Q3 选品无替代/互补关系。** 过滤法独立判断每个单品是否达标，不考虑单品间的需求替代或互补效应。

八、模型的改进与推广

8.1 模型的改进

针对模型缺点，可从以下方向改进：引入多周期动态规划或贝叶斯更新，利用每日新观测修正后续需求预测，改善单周期独立性假设；如获得库存和缺货数据，将建模目标从”销售量”修正为”需求量”；如获得天气和促销数据，作为 Prophet 的外生回归项改善预测精度；对 Q3 引入单品间的交叉弹性，考虑替代和互补效应；对稀疏单品采用分层贝叶斯模型，借用同品类高销量单品的信息改善估计。

8.2 模型的推广

本文模型框架适用于其他易腐生鲜品（水果、乳制品、肉类、烘焙食品）的定价与补货决策。核心组件——Prophet 时序分解、报童随机优化、价格弹性调整——均可直接迁移，仅需根据具体商品的保鲜期调整（单周期 → 多周期）、需求特征调整（季节性强度）和成本结构调整（损耗率、折扣策略）。

在商业应用层面，该模型可为生鲜零售商提供数据驱动的每日补货与定价建议。Prophet 的分解结果可视化有助于管理者理解需求驱动因素，报童模型的优化结果可直接转化为操作指令（各品类/单品的订货量和售价）。随着建议数据（库存记录、折扣原因码、天气数据）的逐步采集，模型预测精度和参数估计可靠性将进一步提升，形成数据采集与模型优化的正向循环。

参考文献

- [1] 全国大学生数学建模竞赛组委会. 2023 年高教社杯全国大学生数学建模竞赛 C 题: 蔬菜类商品的自动定价与补货决策. 2023.
- [2] 吴萌, 张驰, 王志勇. “蔬菜类商品的自动定价与补货决策” 问题解析. 数学建模及其应用, 2024, 13(2): 27–36.
- [3] 曹宇轩, 黄瑞, 秦一天. 基于历史数据的蔬菜类商品定价与补货决策模型. 数学建模及其应用, 2024, 13(2): 37–46.
- [4] 高佳楠, 台明浪, 崔思雨, 李明涛. 蔬菜类商品动态定价与补货决策研究. 数学建模及其应用, 2024, 13(2): 47–56.
- [5] 聂森, 潘萱颖, 曲浩栋. 基于价格弹性的蔬菜类商品自动定价与补货决策. 数学建模及其应用, 2024, 13(2): 66–72.
- [6] 杨若涵, 张莹, 周文可. 基于超市商品补货策略的分析——以 2023 年全国数学建模竞赛 C 题为例. 应用数学进展, 2024, 13(1): 376–391.
- [7] 陈妙霞, 朱映辉, 张赞, 林文雅. 基于 SARIMA 模型的生鲜类商品自动定价与补货决策——以蔬菜类商品为例. 数字技术与应用, 2024, 42(10): 147–150.
- [8] 聂宇旋. 基于 ARIMA 预测优化模型的生鲜类商品自动定价与补货策略研究——以蔬菜类商品为例. 商展经济, 2024(5): 19–22.
- [9] 苏茜, 何暄暄, 卢^[E], 黄亚群. 基于优化模型的蔬菜类商品定价与补货决策. 软件导刊, 2025, 24(6): 87–94.
- [10] Taylor S J, Letham B. Forecasting at scale. The American Statistician, 2018, 72(1): 37–45.
- [11] Dana J D, Petruzzi N C. Note: The newsvendor model with endogenous demand. Management Science, 2001, 47(11): 1488–1497.
- [12] Qin Y, Wang R, Vakharia A J, et al. The newsvendor problem: Review and directions for future research. European Journal of Operational Research, 2011, 213(2): 361–374.
- [13] 周志华. 机器学习. 北京: 清华大学出版社, 2016.
- [14] 王燕. 应用时间序列分析 (第 5 版). 北京: 中国人民大学出版社, 2022.

附录

附件 A：支撑材料说明

表 9 支撑材料文件清单

文件	说明
code/Q1/q1_main.py	Q1 主程序：Spearman 相关 + K-means++ 聚类 + 分布拟合
code/Q1/q1_baseline.py	Q1 对比程序：Pearson 相关 + 层次聚类
code/Q2/q2_main.py	Q2 主程序：Prophet 分解 + 约束报童优化
code/Q2/q2_baseline.py	Q2 对比程序：ARIMA + 固定加成
code/Q3/q3_main.py	Q3 主程序：单品过滤 + 单品报童优化
code/Q3/q3_baseline.py	Q3 对比程序：固定加成策略
code/scripts/clean_data.py	数据清洗脚本
code/scripts/robustness_checks.py	稳健性检查脚本
results/QX/reports/frozen_numbers.json	冻结数值快照

附件 B：Q3 单品级策略详表（部分）

受篇幅限制,31 个单品的完整最优策略见支撑材料中的 q3_m1_sku_policy.csv 文件。表10展示各品类代表单品的结果。

表 10 Q3 部分单品最优策略

品类	入选数	品类最优订货量 (kg)	品类利润贡献（元）
水生根茎类	3	17.1	79
花叶类	12	142.7	322
花菜类	2	28.2	131
茄类	3	39.2	146
辣椒类	6	132.0	342
食用菌	5	77.1	161