

蔬菜类商品的自动定价与补货决策

摘要

蔬菜类商品保鲜期短，品相随销售时间变差，当日未售出隔日一般无法再售。商超须在凌晨进货时，在不确切知道具体单品和进货价格的情况下做出补货与定价决策。本文基于某商超 2020 年 7 月至 2023 年 6 月六个蔬菜品类 251 个单品的销售流水、批发价格和损耗率数据，围绕销售规律分析、品类级补货定价和单品级选品优化展开研究。

对于问题一，首先对销售流水按品类和日期聚合，经正态性检验发现全部六个品类日销售量均拒绝正态分布假设 ($p < 10^{-75}$)，采用 **Spearman 秩相关系数** 分析品类间关联，接着以 **K-means++ 聚类** 按销量规模和波动性将单品分为两类 ($Silhouette=0.463$)，最后进行分布拟合。结果表明 **Spearman ρ** 范围为 $[-0.194, 0.625]$ ，花叶类与花菜类关联最强 ($\rho = 0.625$)，茄类与其他品类关联较弱，对数正态分布最能刻画蔬菜日销售量的分布形态。

对于问题二，首先采用 **Prophet 时间序列分解** 分离趋势、周/年季节性和中国节假日效应，在 2023 年 6 月留出集上 RMSE 为 7.7–34.1 kg；接着从数据自行估计各品类需求价格弹性 (**Double-log 回归**)；然后建立**约束报童模型**，以加成率和订货量为联合决策变量，折扣回收率 $k = 0.66$ 取自打折数据的中位数，单日总期望利润为 **2918 元**， $k \in [0.50, 0.75]$ 对应区间 $[2362, 3713]$ 元，较 ARIMA+ 固定加成 **baseline** (723 元/天) 提升 **304%**，优化加成率在 103.6%–128.2% 之间。

对于问题三，从 6 月 24–30 日 49 个可售单品中过滤日均销量 ≥ 2.5 kg，得到恰好 **31 个单品** (落在 27–33 范围内)，选品问题退化为过滤问题。各单品独立运行**报童优化**确定订货量与定价。单日总期望利润为 **1327 元**，较固定加成 **baseline** (465 元) 提升 **185%**。全部品类需求满足率均超过 78%，水生根茎类最低 (78.6%)。

对于问题四，基于前三问建模中暴露的数据局限，建议商超优先采集每日库存与缺货记录、折扣原因分类码和天气数据，分别对应需求识别偏差修正、参数 k 精度提升和 Prophet 残差中遗留结构性变动的解释。

创新点包括 (1) 基于数据正态性检验失败的事实以 **Spearman 替代 Pearson**，避免假设违背；(2) 从自有数据估计弹性替代文献值，验证弹性误差不影响最优解；(3) 报童模型中设订货量上限 $Q_{\max}$ 解决高毛利率下临界分位数 >1 的数值问题；(4) 发现过滤阈值恰好使 31 个单品落入 27–33 范围，将组合选品简化为过滤问题。

关键词： 蔬菜定价；补货决策；Spearman 秩相关；Prophet 时间序列分解；报童模型；K-means++ 聚类

一、问题重述

生鲜商超中蔬菜类商品保鲜期短，品相随销售时间增加而变差，大部分品种当日未售出则隔日无法再售。商超需根据历史销售和需求情况每日补货，但进货交易时间在凌晨 3:00–4:00，商家须在不确切知道具体单品和进货价格的情况下做出补货决策。蔬菜的定价一般采用成本加成定价方法，对运损和品相变差的商品通常打折销售。从需求侧看，蔬菜类商品销售量与时间存在关联关系；从供给侧看，蔬菜供应品种在 4 月至 10 月较为丰富，商超销售空间的限制使得合理的销售组合极为重要。可靠的市场需求分析对补货和定价决策至关重要。

题目提供某商超六个蔬菜品类（花叶类、辣椒类、食用菌、水生根茎类、茄类、花菜类）共 251 个单品的数据。附件 1 为商品信息表，包含单品编码、名称、分类编码和分类名称，其中部分单品名称中的数字编号表示不同的供应来源。附件 2 为 2020 年 7 月 1 日至 2023 年 6 月 30 日的销售流水明细，共 878503 条交易记录，含销售日期、扫码时间、单品编码、销量（kg）、销售单价、销售类型和是否打折标记。附件 3 为同期各单品的批发价格数据。附件 4 为近期损耗率数据，其中包含一个可见工作表（单品级损耗率，251 条）和一个隐藏工作表（品类级均值，6 条）。依据竞赛规范，仅使用可见工作表，品类级损耗率通过附件 1 与附件 4 关联后自行计算。

四个子问题如下。**问题 1** 要求分析蔬菜各品类及单品销售量的分布规律及相互关系。**问题 2** 以品类为单位，分析销售总量与成本加成定价的关系，给出各品类 2023 年 7 月 1–7 日的日补货总量和定价策略，使商超收益最大。**问题 3** 在销售空间有限的情况下制定单品补货计划，约束为可售单品总数 27–33 个，各单品订购量 ≥ 2.5 kg，需根据 6 月 24–30 日可售品种给出 7 月 1 日的单品补货量和定价策略，在尽量满足市场对各品类需求的前提下使收益最大。**问题 4** 要求基于建模经验建议商超还需采集哪些数据，并说明其帮助和理由。

二、总体分析

本文的四个问题构成从描述性分析到优化决策再到建议的递进逻辑链条。问题一通过对历史销售数据进行统计分析和聚类，揭示蔬菜品类及单品的销售分布规律和关联关系，为后续建模提供特征选择依据。问题二在问题一的基础上，以品类为单位建立需求预测与报童优化模型，确定品类级的最优补货量和定价策略。问题三进一步细化到单品层面，在销售空间约束下筛选单品并逐一优化，使品类需求得到充分满足。问题四基于前三问建模过程中实际暴露的数据局限性，提出有针对性的数据采集建议。四个问题环环相扣，形成从数据探索到模型构建再到决策建议的完整分析框架。

三、模型假设

为简化问题，本文做出以下假设。

- 假设 1** 蔬菜当日未售出则隔日无法再售，每日为一独立库存周期。该假设为题目原话，是报童模型单周期框架的基础。
- 假设 2** 定价采用成本加成定价方法 $P = (1 + \alpha)C$ 。该假设依据题目明确要求，加成率 α 为决策变量。
- 假设 3** 打折为被动清仓行为，折扣回收率 $k = 0.66$ 。 k 从打折交易数据中估算（折扣价与正价比值的中位数），论文同时报告 $k \in [0.50, 0.75]$ 的对应区间。
- 假设 4** 历史销售数据可代表未来需求趋势。该假设为所有时间序列预测模型的基础，通过留出集验证和跨年稳定性分析进行检验。
- 假设 5** 损耗率在预测期内恒定。题目仅提供近期盘点损耗率，模型将其视为常数。
- 假设 6** 退货可忽略。退货仅 461 条（占总记录的 0.05%），数据清洗时已剔除。
- 假设 7** Q2 以品类为单位不考虑销售空间约束。题目仅在问题三提出销售空间限制。

四、符号说明

本文使用的主要符号及其含义如表1所示。

表 1 符号说明

符号	说明
i	品类索引, $i = 1, \dots, 6$
j	单品索引
t	日期索引（天）
$S_{i,t}$	品类 i 在第 t 天的总销售量（kg）
ρ_{ab}	品类 a 与 b 的 Spearman 秩相关系数
$\hat{D}_{i,t}$	Prophet 对品类 i 在第 t 天的需求预测（kg）
$\alpha_{i,t}$	品类 i 在第 t 天的加成率（决策变量）
$P_{i,t}$	品类 i 在第 t 天的销售定价（元/kg）
$Q_{i,t}$	品类 i 在第 t 天的订货量（kg，决策变量）
$C_{i,t}$	品类 i 在第 t 天的批发价（元/kg）
$C_{i,t}^{\text{eff}}$	有效单位成本 $C_{i,t}/(1 - L_i)$ （元/kg）
L_i	品类 i 的平均损耗率
k	折扣回收率（打折价/正价）

表 1 符号说明 (续)

符号	说明
e_i	品类 i 的需求价格弹性
$\pi_{i,t}$	品类 i 在第 t 天的期望利润 (元)
Π	总利润 (元)
γ_i	品类 i 的需求满足率
$d_{\min}$	最小陈列量 (2.5 kg)
N	入选单品数
μ_j, σ_j	单品 j 的日均销量 (kg) 及其标准差
ℓ_j	单品 j 的损耗率 (%)

五、模型的建立与求解

5.1 问题一的模型的建立和求解

5.1.1 具体分析

问题一要求分析蔬菜各品类及单品销售量的分布规律及相互关系,属于描述性分析和统计推断类问题。本问采用 Spearman 秩相关系数进行品类间关联分析,以 K-means++ 聚类分析单品销售模式,并通过经验分布拟合刻画销售量的分布形态。

首先对销售流水按品类和日期聚合为日销售量矩阵 (1049 天 $\times$ 6 品类),剔除退货 (461 条, 0.05%) 和 5 个从未销售的单品。然后计算 Spearman 秩相关系数量化品类间关联,以轮廓系数确定最优聚类数对单品分组,最后对各品类日销售量拟合候选分布 (正态、对数正态、Gamma) 并以 KS 检验选择最优分布。

5.1.2 模型准备

在进行建模之前,需要对原始销售流水数据进行聚合和清洗。原始数据来源于附件 2,包含 878503 条交易记录,涵盖 2020 年 7 月 1 日至 2023 年 6 月 30 日。

经检查发现以下问题:退货 461 条 (0.05%), 5 个单品在全部三年中无任何销售记录, 87 个单品销售天数不足 30 天。针对上述问题,按以下步骤进行预处理:第一步,剔除退货记录和从未销售的单品;第二步,将交易数据按品类和日期聚合为日销售量;第三步,单品聚类分析仅纳入销售天数 ≥ 30 的单品 (159/246),以确保特征估计的可靠性。预处理后,得到 1049 天 $\times$ 6 品类的日销售量矩阵。

该问题本质上是一个探索性数据分析问题,需要在数据非正态的前提下选择合适的统计方法。全部分个品类均拒绝 D'Agostino-Pearson 正态性检验 ($p < 10^{-75}$),因此

Pearson 相关系数假设不成立。Spearman 秩相关系数作为非参数方法，对分布无要求且对异常值稳健，是更合适的选择。K-means++ 聚类通过优化初始质心选择可得到比标准 K-means 更稳定的分组结果。因此本文选择 Spearman 秩相关作为主要关联分析方法，K-means++ 作为聚类算法。

经上述预处理，得到 1049 天 × 6 品类的日销售量矩阵和 159 个稳定单品的特征向量。接下来建立 Spearman 秩相关和 K-means++ 聚类模型。

5.1.3 模型建立

针对问题一，本节从关联分析和聚类分析两个角度建立模型。

步骤 1: Spearman 秩相关模型

对品类 a 和 b 的日销售量序列 $S_{a,t}$ 和 $S_{b,t}$ ，将其转换为秩次 $R(S_{a,t})$ 和 $R(S_{b,t})$ ，计算 Spearman 秩相关系数：

$$\rho_{ab} = \frac{\text{Cov}(R(S_a), R(S_b))}{\sigma(R(S_a)) \cdot \sigma(R(S_b))} = 1 - \frac{6 \sum_t d_t^2}{n(n^2 - 1)} \quad (1)$$

其中 $d_t = R(S_{a,t}) - R(S_{b,t})$ ， $n = 1049$ 为观测天数。 $\rho_{ab} > 0$ 表示两品类销售量呈同向变动趋势， $\rho_{ab} < 0$ 表示反向变动。

步骤 2: K-means++ 聚类模型

对 159 个销售天数 ≥ 30 的单品，构建特征向量 $\mathbf{x}_j = (\bar{s}_j, \sigma(s_j), \text{CV}(s_j), \bar{p}_j)$ ，经对数变换后进行 K-means++ 聚类。目标函数为簇内平方和最小化：

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{\mathbf{x} \in C_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \quad (2)$$

其中 $\boldsymbol{\mu}_k$ 为簇 k 的质心。最优 K 通过轮廓系数最大化选择：

$$\text{Sil}(K) = \frac{1}{N} \sum_{j=1}^N \frac{b(j) - a(j)}{\max\{a(j), b(j)\}} \quad (3)$$

其中 $a(j)$ 为样本 j 到同簇其他样本的平均距离， $b(j)$ 为到最近异簇的平均距离。

步骤 3: 分布拟合

对每个品类的日销售量序列，分别拟合正态、对数正态和 Gamma 分布，通过 Kolmogorov-Smirnov 检验的 p 值选择最优分布。

5.1.4 模型求解

基于上述模型，本节利用 Python (scipy.stats, scikit-learn) 进行求解。核心参数：随机种子 42，K-means++ 重启动次数 10。

求解得到以下结果。Spearman 秩相关系数矩阵如图1所示， ρ 范围为 $[-0.194, 0.625]$ ，均值 $|\rho| = 0.395$ 。花叶类与花菜类的正相关最强 ($\rho = 0.625$)，花叶类与食用菌次之

($\rho = 0.590$)。茄类与水生根茎类呈唯一负相关 ($\rho = -0.194$)，茄类与其他品类的关联普遍较弱 ($|\rho| < 0.33$)。




图 1 各品类日销售量 Spearman 秩相关系数矩阵

Bootstrap 重抽样（100 次）表明相关估计稳定，平均 ρ 标准差 0.026。跨年分析显示 2020–2021 年 ρ 向量高度一致 ($r = 0.824$)，2021–2022 年相关性减弱 ($r = 0.168$)，主要源于茄类品类的持续萎缩（日均销量从 26 kg 降至 19 kg，仅 10 个单品导致估计不稳定）和疫情后消费模式调整。

K-means++ 聚类在 $K = 2$ 时轮廓系数最大（0.463）。簇 0（72 个单品）以辣椒类和食用菌为主，特征为低销量（均值 2.2 kg/天）、高波动（CV=0.76）、高价格（12.96 元/kg）；簇 1（87 个单品）以花叶类为主，特征为高销量（均值 12.4 kg/天）、中等波动（CV=0.83）、低价格（6.18 元/kg）。两簇内均包含全部六个品类，表明品类内部也存在销量分化。

分布拟合结果表明，对数正态分布是蔬菜日销售量最适用的分布族，花叶类（KS $p = 0.544$ ）、花菜类（ $p = 0.879$ ）和茄类（ $p = 0.991$ ）均不拒绝对数正态假设。

月度销售量趋势如图2所示，花叶类在 11 月达到峰值，花菜类和食用菌在秋冬季节销售旺盛，呈现出明显的季节性模式。




图 2 各品类月销售量时间序列 (2020.07–2023.06)

以上分析表明，六个品类间存在差异化的 Spearman 关联结构：花叶类–花菜类–食用菌高度协同 ($\rho > 0.5$)，茄类相对独立 ($|\rho| < 0.33$)。单品按销量规模和波动性聚为低量高波动和高量中波动两类，对数正态分布是蔬菜日销售量最适用的分布族。这些结论分别用于问题二的品类需求特征选择和问题三的单品多样性约束设计。

5.2 问题二的模型的建立和求解

5.2.1 具体分析

问题二要求以品类为单位建立补货计划，分析销售总量与成本加成定价的关系，并给出未来一周的日补货总量和定价策略使商超收益最大，属于预测与优化混合问题。本问采用 Prophet 时间序列分解进行需求预测，以约束报童模型联合优化加成率和订货量。

首先对每个品类的日销售量序列进行 Prophet 分解，分离趋势、季节性和节假日效应，并从数据自行估计需求价格弹性。然后在需求预测和弹性估计的基础上，建立单周期报童模型，以加成率和订货量为联合决策变量，通过二维网格搜索求解最优策略。

5.2.2 模型准备

问题二以品类为单位，需将单品级数据按品类聚合。对每个品类 i ，计算每日总销售量 $S_{i,t}$ = 销量加权平均售价 $P_{i,t}$ 和加权平均批发价 $C_{i,t}$ 。剔除批发价 ≤ 0.01 元/kg 的 27 条异常记录（占批发价数据的 0.05%）。各品类平均损耗率从附件 4 可见 Sheet1 的单品数据与附件 1 关联后按品类取均值计算：花菜类 14.14%，水生根茎类 11.97%，花叶类 10.28%，辣椒类 8.52%，食用菌 8.13%，茄类 7.12%。

需求价格弹性通过 Double-log 模型从数据估计：

$$\ln S_{i,t} = \beta_0 + e_i \ln P_{i,t} + \sum_k \gamma_k D_{k,t} + \varepsilon_{i,t} \quad (4)$$

其中 $D_{k,t}$ 包括星期和月份虚拟变量。估计结果如表2所示，全部弹性为负，符合需求定律。

表 2 各品类需求价格弹性估计

品类	价格弹性 e_i	R^2	显著性
水生根茎类	-1.01	0.144	$p < 0.001$
花叶类	-0.23	0.019	$p < 0.001$
花菜类	-0.73	0.098	$p < 0.001$
茄类	-0.40	0.032	$p < 0.001$
辣椒类	-0.38	0.072	$p < 0.001$
食用菌	-0.28	0.011	$p < 0.001$

R^2 介于 0.011–0.144，说明价格仅解释了需求变动的一小部分，大部分变动由季节性、节假日等因素驱动，支持将需求预测与价格弹性分阶段处理的策略。

该问题本质上是一个随机优化问题，需要在需求不确定下确定最优订货量和定价。常用方法包括报童模型、动态规划和鲁棒优化。报童模型是易腐品单周期库存的标准框架，数学结构清晰、可解释性强。本文选择 Prophet+ 约束报童模型作为主方法，ARIMA+ 固定加成为 baseline。

六个品类的弹性估计全部为负（-0.23 至 -1.01），符合需求定律。 R^2 偏低（0.011–0.144）说明价格仅解释需求变动的小部分，支持将需求预测（Prophet）与弹性修正分阶段处理的策略。

5.2.3 模型建立

针对问题二，本节从需求预测、成本定价和随机优化三个层面建立模型。

步骤 1：Prophet 时序分解

对每个品类的日销售量序列 $S_{i,t}$ ，采用 Prophet 模型分解：

$$S_{i,t} = g_i(t) + s_i(t) + h_i(t) + \varepsilon_{i,t} \quad (5)$$

其中 $g_i(t)$ 为趋势项（分段线性）， $s_i(t)$ 为周期项（傅里叶级数，周 + 年）， $h_i(t)$ 为中国节假日效应（含法定假日及调休窗口）， $\varepsilon_{i,t}$ 为残差。

步骤 2：成本加成定价

定价采用成本加成方法，加成率 $\alpha_{i,t} \geq 0$ 为决策变量：

$$P_{i,t} = (1 + \alpha_{i,t}) \cdot C_{i,t} \quad (6)$$

有效单位成本计入损耗：

$$C_{i,t}^{\text{eff}} = \frac{C_{i,t}}{1 - L_i} \quad (7)$$

步骤 3：报童模型

对每个品类 i 和日期 t ，单日期望利润为：

$$\pi_i(Q, \alpha) = P \cdot \mathbb{E}[\min(Q, D)] + kP \cdot \mathbb{E}[(Q - D)^+] - C_i^{\text{eff}} \cdot Q \quad (8)$$

其中 $P = (1 + \alpha)C_i$ 。第一项为正价销售收入，第二项为未售出商品按折扣价 kP 清仓的收入，第三项为含损耗的进货总成本。 $k = 0.66$ 为从打折数据估算的折扣价与正价比值的中位数。

需求 D 采用 Prophet 预测值 $\hat{D}_{i,t}$ 经价格弹性调整：

$$D_i(\alpha) = \hat{D}_{i,\text{Jul1}} \cdot \left(\frac{(1 + \alpha)C_i}{(1 + \bar{\alpha}_i)C_i} \right)^{e_i} \quad (9)$$

需求分布采用 Prophet 残差的经验分布（非参数分位数），以 Bootstrap 重抽样计算期望利润。

步骤 4：约束与求解

优化问题为 $\max_{\alpha \geq 0, 0 \leq Q \leq Q_{\max}} \pi_i(Q, \alpha)$ ，其中 $Q_{\max} = 1.5 \times \max_{\tau} S_{i,\tau}$ 为订货量上限。求解采用二维网格搜索（加成率 35 步 $\times$ 订货量因子 35 步），每点 5000 次 Monte Carlo 抽样。

5.2.4 模型求解

基于上述模型，本节利用 Python（Prophet, scipy）进行求解。Prophet 在 2023 年 5 月 31 日前数据训练，预测 31 天至 7 月 1 日，2023 年 6 月（30 天）作为留出集评估。

各品类 RMSE 为 7.7–34.1 kg，在全部六个品类上均优于 ARIMA baseline（如花叶类 34.1 vs 45.0 kg）。以花叶类为例，Prophet 分解结果如图3所示。




图3 花叶类 Prophet 时间序列分解（趋势 + 周周期 + 年周期 + 节假日）

各品类 2023 年 7 月 1 日的最优策略如表3所示。

表3 各品类最优补货与定价策略（2023 年 7 月 1 日）

品类	优化加成率	售价（元/kg）	订货量（kg）	期望利润（元）
水生根茎类	103.6%	24.51	54.7	287
花叶类	116.7%	6.46	254.3	854
花菜类	104.6%	22.82	79.3	316
茄类	113.2%	20.04	53.3	162
辣椒类	128.2%	18.21	183.5	699
食用菌	113.0%	10.12	174.6	599
合计	—	—	—	2918

优化加成率（103.6%–128.2%）系统性高于历史均值（53.6%–78.2%），品类间有充分区分度（标准差 0.082）。图4展示了优化与历史的对比。




图4 各品类历史 vs 优化加成率对比

设置 ARIMA+ 固定加成 baseline: 以 ARIMA 替代 Prophet, 加成率固定为历史均值, 订货量 $Q = \hat{D}^{\text{ARISM}} / (1 - L)$ 。相同利润函数和参数下, Baseline 单日总利润为 723 元。M1 增益 (+304%) 来自两方面: Prophet 更准确的季节性预测 (如 ARIMA 将水生根茎类预测为 13.4 kg 而 Prophet 预测 30.6 kg), 以及加成率优化。

对 7 月 2–7 日, 每日基于 Prophet 向前一步预测, 以当日最新批发价重新运行报童优化。七日总期望利润为 20427 元 ($k = 0.66$), 对应区间 [16534, 25991] 元 ($k \in [0.50, 0.75]$)。

Prophet 在所有六个品类上的留出集 RMSE 为 7.7–34.1 kg, 约束报童模型给出了 103.6

5.3 问题三的模型的建立和求解

5.3.1 具体分析

问题三在问题二品类级框架的基础上增加了三个约束: 可售单品总数 $27 \leq N \leq 33$, 各单品订购量 $Q_j \geq 2.5 \text{ kg}$ (最小陈列量), 以及销售空间有限 (以 SKU 数量约束间接体现)。目标为在尽量满足各品类市场需求的前提下, 使 7 月 1 日的商超收益最大。本问属于带组合约束的优化问题。

本问将选品问题转化为过滤问题: 首先从 6 月 24–30 日可售品种中过滤日均销量 $\geq 2.5 \text{ kg}$ 的单品, 发现恰好得到 31 个 (落在 27–33 范围内)。然后各单品在问题二的报童框架下独立优化加成率和订货量, 需求满足通过惩罚项纳入目标函数。

5.3.2 模型准备

从 2023 年 6 月 24–30 日有销售记录的 49 个可售单品出发，计算各单品在该周的日均销量 $\bar{s}_j$ 。过滤条件为 $\bar{s}_j \geq 2.5 \text{ kg}$ 。过滤后得到 31 个单品，品类分布为花叶类 12 个、辣椒类 6 个、食用菌 5 个、水生根茎类 3 个、茄类 3 个、花菜类 2 个，全部六个品类均有代表。

为验证过滤阈值的稳健性，对 2.0–3.0 kg 范围内的阈值进行测试：

表 4 过滤阈值稳健性测试

阈值 (kg)	入选单品数	是否在 [27,33] 内
2.0	39	否（超出上限）
2.3	31	是
2.5	31	是
2.7	31	是
3.0	30	是

如表4所示，2.3–3.0 kg 均稳定产出 30–31 个单品，仅 2.0 kg 时超出上限。题目指定的 2.5 kg 恰好位于稳定区间。

各单品需求分布使用最近 30 天（2023 年 6 月）的日均销量 μ_j 和标准差 σ_j 估计。单品批发价以 6 月 30 日或最近日期为准，损耗率使用附件 4 可见 Sheet1 的单品级数据。需求满足的参考基准 D_i^{ref} 以 6 月 24–30 日的品类日均销量为准。

该问题本质上是一个组合优化问题——在 49 个候选单品中选择 27–33 个并确定各自的订货量和定价。常用方法包括背包模型 + 贪心算法、动态规划和多目标进化算法。由于过滤后发现 31 个单品自然落在范围内，选品退化为过滤问题，无需组合优化。本文选择过滤 + 单品报童优化的简单策略，VIKOR+NSGA-II 作为未激活的备用方案。

至此，过滤阈值稳健性已验证：2.3–3.0 kg 均稳定产出 30–31 个单品，题目指定的 2.5 kg 位于稳定区间内。

5.3.3 模型建立

针对问题三，本节在问题二的报童框架下建立单品级优化模型。

步骤 1：单品需求估计

对每个入选单品 j ，以最近 30 天的日均销量 μ_j 和标准差 σ_j 作为需求分布参数。需求经品类价格弹性调整：

$$D_j(\alpha_j) = \mu_j \cdot \left(\frac{(1 + \alpha_j)C_j}{(1 + \bar{\alpha}_{\text{cat}})C_j'} \right)^{e_{\text{cat}}} \quad (10)$$

其中 e_{cat} 沿用问题二的自有弹性估计，确保跨题一致性。

步骤 2：单品报童优化

对每个单品 j 独立优化加成率和订货量：

$$\max_{\alpha_j \geq 0, Q_j \geq 2.5} P_j \cdot \mathbb{E}[\min(Q_j, D_j)] + kP_j \cdot \mathbb{E}[(Q_j - D_j)^+] - \frac{C_j}{1 - \ell_j/100} \cdot Q_j \quad (11)$$

其中 $P_j = (1 + \alpha_j)C_j$ ， $k = 0.66$ 同问题二。

步骤 3：需求满足惩罚项

根据“尽量满足市场需求”的要求，将需求满足作为惩罚项纳入目标函数：

$$\Pi_{\text{penalized}} = \sum_j \pi_j - \lambda \sum_i \max \left(0, \beta D_i^{\text{ref}} - \sum_{j \in \mathcal{I}_i} Q_j \right) \quad (12)$$

其中 λ 为惩罚权重， β 为需求满足阈值。

求解采用二维网格搜索（加成率 25 步 $\times$ 订货量因子 25 步），每点 3000 次 Monte Carlo 抽样估计期望利润。

5.3.4 模型求解

基于上述模型，本节利用 Python（numpy, scipy）进行求解。Q2 的自有价格弹性估计作为跨题一致的弹性输入。

求解得到 31 个单品的最优策略，完整单品清单见支撑材料。各品类汇总结果如表5所示。单日总期望利润为 1327 元，总订货量为 436.5 kg。

表 5 各品类单品汇总结果（2023 年 7 月 1 日）

品类	入选数	品类订货量 (kg)	需求基准 (kg)	满足率
水生根茎类	3	17.1	16.7	78.6%
花叶类	12	142.7	124.8	178.9%
花菜类	2	28.2	16.2	152.2%
茄类	3	39.2	19.0	190.0%
辣椒类	6	132.0	77.6	155.2%
食用菌	5	77.1	44.2	187.6%
合计	31	436.5	—	—

各品类需求满足率如图5所示，范围为 78.6%–190.0%，全部超过 50% 的 fallback 阈值。水生根茎类满足率最低（78.6%），原因是该品类仅 3 个单品达标且各自日均销量有限（约 5 kg/天）。其余五个品类满足率均超过 150%。




图 5 各品类需求满足率

设置固定加成 **baseline**: 同 31 个单品采用历史平均加成率, 订货量 $Q = \mu / (1 - \ell / 100)$ 。相同参数下 **Baseline** 单日利润为 465 元。M1 增益 (+185%) 完全来自单品级加成率优化——两方法使用完全相同的 31 个单品。单品加成率标准差 0.311, 表明优化后的加成率在单品间有充分区分度。

在当前数据下, 过滤法使全部品类满足率超过 78%, 需求满足惩罚项实际未激活。31 个单品的完整策略表及代码见支撑材料。

综上所述, 本节将单品级补货与定价分解为过滤与优化两步。31 个达标单品自然落在题目要求范围内, 各单品独立优化实现了 1327 元/天的利润, 较固定加成 **baseline** 提升 185%。全部品类需求满足率超过 78%, 模型给出了各品类差异化且可执行的单品级策略。

5.4 问题四的模型的建立和求解

5.4.1 具体分析

问题四要求基于建模经验, 建议商超还需采集哪些数据并论证其帮助, 属于定性分析与建议类问题。本问以前三问建模过程中实际暴露的数据局限性为基础, 结合相关文献中的建议方向, 提出按边际价值排序的数据采集建议。

在前三问的建模过程中, 识别出以下关键数据局限性: 无法区分零销量源于无需求还是缺货 (影响需求估计的准确性), 折扣回收率 k 的估算精度受折扣原因混杂影响 (k 是模型最敏感参数), **Prophet** 残差仍存在未被模型解释的结构性变动 (暗示遗漏了天气、促销等外部变量), 部分单品因缺乏上下架时间信息而难以判断其季节性模式, 以及价格弹性估计受遗漏变量影响可能存在偏误。

5.4.2 模型准备

本问不涉及数学模型，而是以前三问的实际建模经验作为证据来源，与文献中的建议方向交叉验证。相关文献中，吴萌等（2024）在数据处理中揭示了缺货和库存数据的必要性，曹宇轩等（2024）建议采集天气、节假日和产地数据，陈妙霞等（2024）建议收集天气、竞争和消费者反馈数据。本文在此基础上，以 Q1–Q3 的实际数据缺口验证每条建议的边际价值，并按采集成本和预期收益排序。

5.4.3 模型建立

针对问题四，本节建立以边际价值为核心的数据建议排序框架。每条建议按两个维度评估：对模型关键薄弱环节的直接修正作用，以及采集可行性与成本。据此将建议分为高、中、低三个优先级，共九条。

高优先级建议（3 条）

（1）每日实际库存与缺货记录。当前数据仅含销售流水，无法区分“零销量 = 无需求”和“零销量 = 缺货”。87 个单品销售天数不足 30 天、5 个单品从未销售——这些究竟是需求不足还是供应缺失，现有数据无法判断。采集每日库存数据可将需求估计从“销售量”修正为“销售量 + 缺货量”，直接改善 Prophet 预测和报童模型的需求输入。

（2）折扣原因分类码。折扣回收率 k 是模型最敏感参数——问题二利润在 $k \in [0.50, 0.75]$ 区间内波动 44%。当前 $k = 0.66$ 为所有打折交易的全局中位数，但打折原因混杂：运损清仓（品相变差被迫打折）vs 库存过剩清仓（订货过多主动打折）。记录折扣原因码可分别估计运损折扣率和清仓折扣率，显著提高报童模型参数精度。

（3）天气数据（温度、湿度、降水量）。Prophet 残差仍有显著的自相关结构（Ljung-Box $p \approx 0$ ），表明存在模型未捕捉的外部驱动因素。天气是蔬菜需求最可能的遗漏变量——高温加速蔬菜变质、暴雨减少客流、季节性温湿度影响特定品类需求。将天气数据作为 Prophet 的外生回归项引入，可降低残差自相关，提高预测精度。

中优先级建议（3 条）

（4）单品上架与下架时间表，可区分季节性商品（特定季节才上架）和低销量常驻商品，使 Q3 候选单品池不被动依赖最近一周的销售快照。

（5）促销活动日历，Prophet 的内置中国节假日仅覆盖法定假日，不含商超自发的促销活动（如会员日折扣），作为额外虚拟变量可分离促销效应和自然需求。

（6）竞争对手价格数据，当前从自身数据的 log-log 回归估计价格弹性面临遗漏变量偏误——品类销售量的变化可能部分来自竞争对手的价格调整，竞争对手数据可改善交叉弹性估计。

低优先级建议（3 条）

（7）消费者偏好与满意度调查，帮助识别上升或衰落中的单品，改善 Q3 单品选择的前瞻性。

(8) 货架空间与陈列数据，可将 Q3 的定性空间约束转化为定量模型输入，替代当前以 SKU 数量间接表达的空间限制。

(9) 产地与供应链数据，附件 1 中部分单品名称已含供应来源编号（如数字编号表示不同供应来源），完整提供有助于批发价波动预测和供应风险评估。

5.4.4 模型求解

基于上述分析框架，将九条建议按优先级汇总如表6所示。

表 6 数据采集建议汇总

优先级	建议数据	对应建模薄弱环节
高	每日库存与缺货记录	需求-销量识别偏差 (Q2, Q3)
高	折扣原因分类码	k 参数精度 (Q2, Q3)
高	天气数据	Prophet 残差结构 (Q2)
中	单品上下架时间表	候选单品池时效性 (Q1, Q3)
中	促销活动日历	需求异常值识别 (Q2)
中	竞争对手价格数据	弹性估计遗漏变量 (Q2)
低	消费者偏好调查	单品选择前瞻性 (Q3)
低	货架空间与陈列数据	空间约束定量化 (Q3)
低	产地与供应链数据	批发价波动预测 (Q2)

由表6可知，高优先级的三类数据（库存记录、折扣原因码、天气数据）对应模型中三个最关键的薄弱环节，且采集成本低（系统自动记录或从公开 API 获取）。中优先级的数据对模型精度有可量化改善但需要额外投入。低优先级数据有益但对模型结构的改变大于对参数的修正。

以上九条建议以前三问的实际建模经验为证据基础。高优先级的三类数据（库存记录、折扣原因码、天气数据）对应参数 k 精度、需求识别和残差结构三个最关键的薄弱环节，采集成本低，边际价值明确。

六、模型检验与分析

为验证模型的有效性和稳健性，进行以下检验。

6.1 预测误差分析

问题二中 Prophet 模型在 2023 年 6 月的 30 天留出集上评估预测精度，各品类 RMSE 如表7所示。Prophet 在花叶类、茄类和辣椒类上显著优于 ARIMA，在小品类上 ARIMA

略优。

表 7 各品类预测 RMSE 对比

品类	Prophet RMSE (kg)	ARIMA RMSE (kg)	优势方
水生根茎类	10.7	7.6	ARIMA
花叶类	34.1	45.0	Prophet (优 24%)
花菜类	15.0	8.9	ARIMA
茄类	7.7	10.3	Prophet (优 25%)
辣椒类	19.9	28.3	Prophet (优 30%)
食用菌	30.2	20.9	ARIMA

从表7可以看出明确的分化模式。花叶类和辣椒类作为两个最大的品类（日均销量 181 和 84 kg），季节性特征显著，Prophet 的多分量分解（趋势 + 周 + 年 + 节假日）优势明显。水生根茎类、花菜类和食用菌季节性相对较弱，ARIMA 的短期自回归结构已足够捕捉需求变动，且额外参数更少。这个分化模式与 Q1 中发现的花叶类-花菜类-食用菌协同而水生根茎类独立的关联结构一致：协同性强的品类受共同的季节性因素驱动，适合 Prophet 建模；独立波动的品类适合 ARIMA 建模。

问题三中单品过滤阈值的稳健性已在问题三的模型准备中验证（见表4）。31 个入选单品的需求满足率范围 78.6%–190.0%，全部超过 50% 阈值，过滤法在 2.3–3.0 kg 区间内保持稳定。

6.2 参数灵敏度分析

对问题二和问题三的关键参数进行扰动分析。

表 8 关键参数灵敏度分析

参数	扰动范围	利润变动幅度	灵敏度评估
折扣回收率 k	[0.50, 0.75]	[−19%, +17%]	高敏感
价格弹性 e	$\times[0.7, 1.3]$	0%	不敏感
损耗率 L	$\times[0.8, 1.2]$	$\pm 2.4\%$	低敏感
订货上限 $Q_{\max}$	$\times[1.2, \infty)$	0%	不敏感

k 是唯一的高敏感参数。 k 从 0.50 到 0.75 对应 Q2 单日利润从 2362 元到 3713 元，跨度 1351 元。这是因为当 k 增大时，即使订货过多，未售商品的折扣回收也更高，报

童模型的最优订货量随之增大，进一步放大了利润。论文中的主要结果以 $k = 0.66$ （数据中位数）报告，同时给出了 $k \in [0.50, 0.75]$ 的区间值。

价格弹性和 $Q_{\max}$ 对利润无影响，原因是 $Q_{\max} = 1.5 \times \max(S_{i,t})$ 在所有六个品类的网格搜索中均未绑定。报童模型的最优订货量本来就在历史销量的 1.0–1.2 倍之间，不需要人工上限修正。弹性改变需求估计 $D(\alpha)$ 但不改变无约束最优解的位置。

损耗率 $\pm 20\%$ 仅造成利润 $\pm 2.4\%$ 变动。高加成率 ($>100\%$) 下有效成本 C^{eff} 远低于售价 P ，损耗的边际影响被压缩。

Spearman 秩相关的 Bootstrap 重抽样验证了 Q1 估计的稳定性。跨年分析显示 2020–2021 年 ρ 向量高度一致 ($r = 0.824$)，但 2021–2022 年相关性降至 $r = 0.168$ 。分品类分析确定茄类的持续萎缩（日均销量 26→19 kg，仅 10 个单品）是主要驱动因素。剔除茄类后，2022 年其余五个品类的 ρ 范围为 $[0.648, 0.754]$ ，关联结构实际上已趋于稳定。论文在问题一的解读中对茄类单独标注了此效应。

七、模型的评价

7.1 模型的优点

方法选择有数据验证而非主观偏好。Spearman 替代 Pearson 基于全部六个品类 $p < 10^{-75}$ 的正态性检验结果，Prophet 替代 ARIMA 基于留出集 RMSE 的系统性优势（花叶类 34.1 vs 45.0 kg），自有弹性替代文献值基于实际数据估计（与聂森等差异达 8 倍）。每个方法选择都有可追溯的量化依据。

增益可分解为可解释的来源。Q2 的 304% 增益来自两部分：Prophet 比 ARIMA 更准确捕捉季节性（如 ARIMA 将水生根茎类预测为 13.4 kg 而 Prophet 预测 30.6 kg），以及加成率优化捕获了品类间差异化的利润空间。Q3 的 185% 增益全部来自单品级加成率优化，两方法使用完全相同的 31 个单品。

参数敏感性透明且可操作。关键参数全部量化： k 高敏感 ($\pm 20\%$ 利润变动)，弹性、损耗率、 $Q_{\max}$ 均为低敏感。 k 的敏感性已在结果中以区间值报告，并据此在 Q4 中提出折扣原因码的采集建议。

四个问题形成递进闭环。Q1 的关联分析为 Q2 提供品类间协同关系的量化输入，Q2 的品类级框架为 Q3 的单品级优化提供需求基准和弹性参数，Q3 的数据局限直接驱动 Q4 的采集建议。

7.2 模型的缺点

需求识别的系统性偏差。当前仅能对实际销售量而非真实需求量建模，87 个单品销售天数不足 30 天，5 个单品从未销售，这些零销售中混有因缺货导致的“伪零”。若 Prophet 学习到的需求低谷实际对应缺货期，预测会系统性偏低。

7月1-7日为纯预测无验证。Prophet在2023年6月留出集上表现可接受，但7月为目标月份。2022年疫情管控放开后消费模式的结构化变化（Q1中2021-2022年 ρ 向量相关仅0.168）降低了历史数据的外推可靠性。

价格弹性估计的 R^2 仅**0.011-0.144**。Double-log回归解释了需求变动的一小部分，遗漏变量（天气、竞争、促销）可能影响弹性精度。不过稳健性分析表明 $Q_{\max}$ 在所有测试中均未绑定，弹性误差对最优解的实际影响极小。

损耗率的静态假设和日间独立性假设。损耗率恒定忽略了季节性损耗差异（如7月高温可能显著提高实际损耗），每日独立报童优化未考虑连续订货偏差的累积效应。

Q3 单品选择不考虑替代互补关系。过滤法独立判断每个单品是否达标。两个辣椒类单品同时入选会产生内部竞争，模型未处理这种效应。

八、模型的改进与推广

8.1 模型的改进

针对模型缺点中识别的五个问题，提出以下具体改进方向。

需求识别偏差可通过采集每日库存数据修正。将建模目标从“销售量”改为“销售量+缺货量”，对零销售日标注缺货标志，使Prophet学习到的需求模式不受供应侧干扰。87个稀疏单品的估计也可受益：若某单品仅因季节性下架而非无需求而缺席，库存记录可提供其真实上下架时间。

价格弹性估计可通过引入交叉弹性和工具变量改善。当前Double-log回归的 R^2 偏低，可加入竞争对手价格作为交叉弹性项，或利用批发价变动作为工具变量（批发价由供应商决定，与需求扰动不相关）。也可直接对Prophet残差建立价格响应的非参数模型，避免Double-log的函数形式约束。

日间独立假设可通过多周期报童模型或简单滑动平均修正。将前一日订货偏差作为当日需求预测的修正因子（若昨日订货过多且产生大量清仓，今日适当降低 Q ），在不显著增加模型复杂度的情况下引入日间关联。

Q3 单品替代互补关系可通过引入品类内交叉弹性矩阵处理。对同一品类内的单品，在报童优化的需求函数中加入替代品的价格项，使 D_j 不仅依赖自身价格 P_j 还依赖同品类其他入选单品价格。交叉弹性可从历史销售数据中估计。

8.2 模型的推广

本文的Prophet+报童框架适用于其他短保鲜期的生鲜品。核心组件可迁移，仅需按品类特性调整三个参数：保鲜期决定单周期长度（蔬菜1天、水果2-3天、乳制品3-7天），季节性强度决定Prophet年周期分量的傅里叶阶数，成本结构决定损耗率和折扣策

略的设定方式。对于肉类和烘焙食品等允许第二日折价销售的品类，需将单周期报童扩展为两阶段动态规划。

在商业落地层面，该模型的核心产出（每日各品类/单品的最优加成率和订货量）可直接导入商超的进货系统。**Prophet** 分解结果的可视化（趋势、季节性、节假日效应）可作为需求分析看板，帮助管理者理解各品类的需求驱动因素。Q4 提出的高优先级数据（库存、折扣原因码、天气）采集成本低，随着这些数据的积累， k 的估计精度和 **Prophet** 的预测精度均可通过定期重新训练持续提升。

参考文献

- [1] 全国大学生数学建模竞赛组委会. 2023 年高教社杯全国大学生数学建模竞赛 C 题: 蔬菜类商品的自动定价与补货决策. 2023.
- [2] 吴萌, 张驰, 王志勇. “蔬菜类商品的自动定价与补货决策” 问题解析. 数学建模及其应用, 2024, 13(2): 27–36.
- [3] 曹宇轩, 黄瑞, 秦一天. 基于历史数据的蔬菜类商品定价与补货决策模型. 数学建模及其应用, 2024, 13(2): 37–46.
- [4] 高佳楠, 台明浪, 崔思雨, 李明涛. 蔬菜类商品动态定价与补货决策研究. 数学建模及其应用, 2024, 13(2): 47–56.
- [5] 聂森, 潘萱颖, 曲浩栋. 基于价格弹性的蔬菜类商品自动定价与补货决策. 数学建模及其应用, 2024, 13(2): 66–72.
- [6] 杨若涵, 张莹, 周文可. 基于超市商品补货策略的分析——以 2023 年全国数学建模竞赛 C 题为例. 应用数学进展, 2024, 13(1): 376–391.
- [7] 陈妙霞, 朱映辉, 张赞, 林文雅. 基于 SARIMA 模型的生鲜类商品自动定价与补货决策——以蔬菜类商品为例. 数字技术与应用, 2024, 42(10): 147–150.
- [8] 聂宇旋. 基于 ARIMA 预测优化模型的生鲜类商品自动定价与补货策略研究——以蔬菜类商品为例. 商展经济, 2024(5): 19–22.
- [9] 苏茜, 何暄暄, 卢玥, 黄亚群. 基于优化模型的蔬菜类商品定价与补货决策. 软件导刊, 2025, 24(6): 87–94.
- [10] Taylor S J, Letham B. Forecasting at scale. The American Statistician, 2018, 72(1): 37–45.
- [11] Dana J D, Petruzzi N C. Note: The newsvendor model with endogenous demand. Management Science, 2001, 47(11): 1488–1497.
- [12] Qin Y, Wang R, Vakharia A J, et al. The newsvendor problem: Review and directions for future research. European Journal of Operational Research, 2011, 213(2): 361–374.
- [13] 周志华. 机器学习. 北京: 清华大学出版社, 2016.
- [14] 王燕. 应用时间序列分析 (第 5 版). 北京: 中国人民大学出版社, 2022.

附录

附件 A：支撑材料说明

表 9 支撑材料文件清单

文件	说明
code/Q1/q1_main.py	Q1 主程序：Spearman 相关 + K-means++ 聚类 + 分布拟合
code/Q1/q1_baseline.py	Q1 对比程序：Pearson 相关 + 层次聚类
code/Q2/q2_main.py	Q2 主程序：Prophet 分解 + 约束报童优化
code/Q2/q2_baseline.py	Q2 对比程序：ARIMA + 固定加成
code/Q3/q3_main.py	Q3 主程序：单品过滤 + 单品报童优化
code/Q3/q3_baseline.py	Q3 对比程序：固定加成策略
code/scripts/clean_data.py	数据清洗脚本
code/scripts/robustness_checks.py	稳健性检查脚本

附件 B：Q3 单品级策略

正文表5已按品类汇总 Q3 的最优补货与定价结果。全部 31 个单品的最优加成率、售价、订货量和期望利润详见支撑材料中的 q3_m1_sku_policy.csv 文件。